

=====

VALIDACIONES CIENTÍFICAS – PROYECTO MASIVE-ALS

Versión corregida: 20 de septiembre de 2026 (tarde)

(sustituye a la del 1 de septiembre y a la del 20 sep de la mañana)

=====

Todas las cajas de unión se validaron contra compuestos conocidos con apoyo experimental y señuelos con propiedades físicas equivalentes (peso molecular ± 30 , logP $\pm 1,0$, enlaces rotables ± 2 , similitud $< 0,35$). HERRAMIENTA: curvas ROC; métrica principal AUC; enriquecimiento EF5%. A partir de esta versión se añade además un FONDO DURO (compuestos del mismo tipo químico que el sitio) y una lectura del AUC sin el tamaño.

TABLA DE VALIDACIÓN

Objetivo	Activos	Señuelos	ROC-AUC	Nota
SOD1 – caja inicial	20	199	0,548	posición incorrecta
SOD1 – sitio Trp32	20	199	0,815	† ver corrección
SOD1 – Trp32, sin la serie 2		199	0,601	† la medida honesta
SOD1 – canal Cu/Zn	20	199	0,717	†
SOD1 – interfaz dímero	20	199	0,809	†
SOD1 – Trp32, limpio	7	482	0,515	† (0,671 sin tamaño)
TDP43 – RRM1 (caja 25 Å)	5	73	0,515	insuficiente
TDP43 – RRM1 (caja 4IUF)	5	193	0,612	+
+ reposición del ligando nativo → RMSD 1,75 Å → protocolo válido				
EN ESTE BOLSILLO (no se hereda a otros; ver corrección 1c)				
FUS – modelo 1 (caja 25)	2	87	0,609	sin controles
TDP43 v2 – interfaz	9	122	0,517*	*ver nota
RRM1-RRM2 (26 Å)				

† CORRECCIÓN DEL 20 DE SEPTIEMBRE DE 2026 – LOS POSITIVOS DE SOD1

Los 20 activos de SOD1 NO son veinte compuestos independientes: son 16 del mismo esqueleto de pirazolona (núcleo Murcko repetido) y 18 tienen otro activo a similitud $\geq 0,5$. Sus identificadores van seguidos (ChEMBL2165601...ChEMBL2165614), o sea que vienen del mismo trabajo de química medicinal.

Separando por química:

los 20 activos juntos 0,815
 sólo la serie pirazolona 0,839
 sólo los independientes 0,601 (n = 2)

Es decir: recuperar una serie sembrada y no encontrar al ligando de referencia independiente es una propiedad de la serie, no una prueba de que el método ordene ligandos de SOD1 en general.

Esto es un modo de fallo documentado en la literatura: cuando los activos son análogos entre sí, el enriquecimiento mide la recuperación de la química sembrada, no la discriminación de ligandos (Chen et al., 2019, sobre el sesgo de análogos y señuelos en DUD-E).

LO QUE EL 0,815 SÍ DEMUESTRA: que la CAJA está bien colocada. La misma lista de ligandos da 0,548 en la caja mal puesta y 0,815 en Trp32.

†† CORRECCIÓN DEL 20 DE SEPTIEMBRE DE 2026 – EL RE-ACOPLAMIENTO

Se hizo por fin el control mínimo del acoplamiento: volver a acoplar los ligandos cuya pose está resuelta por cristalografía en el propio bolsillo Trp32 (5-fluorouridina 4A7S, isoproterenol 4A7T, adrenalina 4A7U, dopamina 4A7V) y medir el RMSD frente a la pose experimental (criterio habitual: $\leq 2,0$ Å; tres semillas 42/2026/777).

RESULTADO (RMSD corregido, simetría tenida en cuenta):

isoproterenol	0,48 a 1,28 Å	PASA (todos los protocolos)
adrenalina	0,66 a 0,75 Å	PASA (todos los protocolos)
dopamina	2,9 a 3,2 Å	no pasa
5-fluorouridina	5,4 a 11,3 Å	no pasa (ver nota)

La adrenalina y el isoproterenol redockean bien con ligando flexible o rígido, con vina o vinardo, con caja de 18 o 24 Å y con exhaustividad 8 o 32: la caja del proyecto está donde debe y el protocolo devuelve a su sitio a los DOS LIGANDOS QUE DEFINEN EL BOLSILLO.

La dopamina es un fallo real, y es de puntuación, no de búsqueda: la pose cristalina SÍ se genera (la mejor de los nueve modos queda a 0,74-1,10 Å) pero la función de puntuación prefiere otra a 3,1 Å por ~1,2 kcal/mol. Medido aparte: en este bolsillo la función resuelve medio ángstrom con ~1,5 kcal/mol, así que diferencias de 1-2 kcal/mol no son interpretables. Es el límite del método, no un fallo de ajuste.

NOTA SOBRE LA 5-FLUOROURIDINA: su pose depositada no es un mínimo de la función de puntuación. En 4A7S (1,06 Å de resolución) el ligando tiene un contacto F···N de 2,07 Å y un O···O de 2,34 Å, y puntúa +0,04 kcal/mol; desplazarla 2 Å la lleva a +14,8 kcal/mol. No sirve como patrón de RMSD; el artículo original ya describe su ribosa como expuesta al disolvente y con ocupación baja. Se EXCLUYE como patrón, no se cuenta como fallo del protocolo.

NOTA DE PROCEDENCIA: la primera versión de esta sección dio 1,87-2,54 Å (isoproterenol), 3,77-3,79 Å (adrenalina), 4,04-4,06 Å (dopamina) y 10,89-11,20 Å (5-fluorouridina), y concluyó en falso que el protocolo fallaba en todo. Esos números estaban INFLADOS por un error de programación nuestro en la rutina que empareja los átomos (los índices de la pose y del cristal estaban intercambiados, lo que infla precisamente las poses buenas). Se corrigió y se comprobó contra la implementación de RMSD de RDKit, con coincidencia exacta en las 36 poses. El error fue nuestro.

Informes:

analysis/redocking_trp32/INFORME_CONTROLES_CORREGIDOS_2026-09-20.md
analysis/redocking_trp32/INFORME_REDOCKING_TRP32_2026-09-20.md

††† CORRECCIÓN DEL 20 DE SEPTIEMBRE DE 2026 – LA VALIDACIÓN REHECHA
(conjunto limpio, dos fondos y el tamaño descontado)

Se rehizo toda la validación de SOD1 con el conjunto de controles limpio, declarado por tipo de evidencia, y contra DOS fondos de comparación. Script: analysis/validar_sod1_v3.py. Datos: analysis/validacion_SOD1_v3/.

Grupos de control (sin contar series congénicas más de una vez):

- independientes (2): LCS-1 (piridazinona) y PRG-A01 (cumarina), las dos únicas químias independientes del conjunto.
- serie colapsada a un representante (1): ChEMBL2165613.
- co-cristalizados (4): isoproterenol, adrenalina, dopamina y 5-fluorouridina (PDB 4A7T, 4A7U, 4A7V, 4A7S). Su evidencia es estructural directa: están en el bolsillo.

Fondos:

- emparejado nuevo (140): señuelos del mismo peso ± 30 , logP ± 1 , rotables ± 2 , Tanimoto $< 0,35$.
- emparejado antiguo (199): los señuelos de la validación anterior, ya acoplados en la misma caja.
- duro (143): compuestos de la librería con grupos que QUELAN METALES o son REDOX-ACTIVOS (catecol, pirogalol, quinona, o-aminofenol, hidroxamato, tiol, sulfonato, fosfonato, hidrazida, tiosemicarbazona), es decir la química que de verdad se pegaría a una metaloenzima.

EL SESGO DE TAMAÑO, MEDIDO. Ajustando afinidad frente a número de átomos pesados SOLO con el fondo (N = 482):

afinidad = -3,42 - 0,096 * (átomos pesados)

Cada átomo pesado de más vale 0,096 kcal/mol en esta caja. Con eso se define el «AUC sin tamaño»: el mismo cálculo sobre el residuo del ajuste, que es la parte del score que no explica el tamaño. El ajuste nunca usa los activos.

Grupo	Fondo	AUC	AUC sin tamaño
independientes (2)	emparejado nuevo	0,671	0,486
independientes (2)	emparejado antiguo	0,628	0,566
independientes (2)	duro	0,598	0,462
independientes (2)	los tres juntos	0,632	0,509
serie (1)	los tres juntos	0,932	0,950
co-cristalizados	emparejado nuevo	0,425	0,661
co-cristalizados	emparejado antiguo	0,328	0,746
co-cristalizados	duro	0,316	0,624
co-cristalizados	los tres juntos	0,353	0,682
todos (7)	los tres juntos	0,515	0,671

EF1% = 0 en todas las combinaciones; EF5% = 0 salvo 5,71 en un caso. NINGÚN control entra en el 1% superior de la lista.

PUESTOS frente a los 482 señuelos juntos:

CHEMBL2165613 (serie)	-6,37	puesto 34	(mejor que 93,0 %)
PRG-A01 (cumarina)	-6,19	puesto 44	(90,9 %)
5-fluorouridina	-5,70	puesto 113	(76,6 %)
LCS-1 (piridazinona)	-4,96	puesto 313	(35,2 %)
adrenalina	-4,78	puesto 361	(25,3 %)
dopamina	-4,71	puesto 380	(21,3 %)
isoproterenol	-4,64	puesto 398	(17,6 %)

Los tres últimos tienen la pose resuelta en este mismo bolsillo y el ranking los coloca por debajo del 75-82 % de los señuelos. El 0,815 queda así EXPLICADO de forma cuantitativa: es una serie congénica de moléculas grandes, y el tamaño se paga a 0,096 kcal/mol por átomo.

LO QUE ESTÁ VALIDADO Y LO QUE NO (declaración explícita)

1. EL SITIO ESTÁ VALIDADO. La caja Trp32 es el bolsillo donde la cristalografía sitúa a los cuatro ligandos (Wright et al., 2013), y es la caja que da mejor enriquecimiento de las cuatro comparadas.
2. EL PROTOCOLO ESTÁ VALIDADO PARA EL QUIMIOTIPO CATECOLAMINA DE TRP32. Isoproterenol y adrenalina, los dos ligandos que definen el bolsillo, se reproducen a 0,48-1,28 Å y 0,66-0,75 Å con todos los protocolos probados (flexible/rígido, vina/vinardo, caja 18/24 Å, exhaustividad 8/32). Esta validación es ESPECÍFICA de ese quimiotipo y de ese bolsillo: no se hereda a otros bolsillos ni a otras químias.
3. EL RANKING NO ESTÁ VALIDADO, y ahora se sabe por qué. Los ligandos co-cristalizados puntúan peor que el azar frente a los señuelos emparejados (AUC 0,32-0,43); descontado el tamaño suben a 0,62-0,75, que es «débil», no «validado». Los dos únicos activos independientes quedan en el azar tanto antes como después de descontar el tamaño (0,60-0,67 y 0,46-0,57), y LCS-1 cae en el puesto 313 de 482.
4. En consecuencia, EL 0,815 SIGUE SIENDO PROVISIONAL, y ahora por dos motivos independientes y medidos: los positivos son una sola serie química, y la puntuación de Vina en esta caja está sesgada por el tamaño. No es provisional porque el protocolo no reproduzca poses: reproduce las de las catecolaminas.
5. NINGUNA de las tres listas de candidatos (SOD1, TDP-43, FUS) debe presentarse como validada. Son hipótesis para selección experimental,

que es lo que el artículo dice de forma explícita (sección 5.7).

NOTA SOBRE TDP-43

En TDP-43 v2 (el sitio nuevo, interfaz RRM1-RRM2) el AUC bruto es ~al azar POR EL SESGO DE TAMAÑO CONOCIDO del motor (los señuelos grandes puntúan demasiado bien). Pero los 9 activos acoplan en las mejores posiciones y con energías que REPRODUCEN las publicadas dentro de ~1 kcal/mol:

- PE859: predicho -7,60 frente a -8,49 publicado
- berberrubina: predicho -7,74 frente a -7,72 publicado

Eso confirma que el receptor y el bolsillo están bien definidos.

Lo que NO está demostrado en TDP-43, y hay que decirlo, es que la puntuación ORDENE. Van dos cajas probadas y las dos veces los ligandos conocidos caen al fondo de la tabla. Además, la medida de similitud química que se usó para armar la lista focalizada resultó ser un detector de familia, no un predictor de unión: da AUC 1,000 dentro de su propia familia y 0,538 (azar) fuera de ella, y una sola molécula de referencia bate al conjunto entero de ocho.

El protocolo de TDP-43 (4IUF) sí está validado para la reposición de su ligando nativo (RMSD 1,75 Å), igual que el de Trp32 lo está para las catecolaminas. Cada bolsillo y cada quimiotipo se validan aparte.

CONCLUSIÓN (corregida)

- SOD1: la caja Trp32 está validada como sitio, y el protocolo está validado para el quimiotipo catecolamina (redocking 0,48-1,28 Å). El 0,815 demuestra que la caja está bien colocada, NO que el método ordene ligandos de SOD1: con controles independientes es 0,601 (n=2) y con el conjunto limpio y los dos fondos, 0,515 bruto (0,671 sin tamaño), con los co-cristalizados por debajo del azar.
- TDP-43: protocolo válido (RMSD 1,75 Å en la reposición del ligando nativo) y bolsillo v2 con energías reproducidas. El ORDEN de la lista no está validado.
- FUS: provisional, sin controles propios en la literatura.

Por tanto, NINGUNA de las tres listas de candidatos debe presentarse como validada. Son hipótesis para selección experimental.

CRITERIO QUE SE ADOPTA A PARTIR DE AHORA

Un ranking se considera informativo sólo si coloca positivos de AL MENOS DOS SERIES QUÍMICAS INDEPENDIENTES por delante de los señuelos emparejados. Un conjunto de positivos de una sola química no se reporta como prueba de capacidad de orden. Y el fondo de comparación debe ser difícil (señuelos emparejados en propiedades y, para metaloenzimas, un fondo de quelantes y redox-activos), no moléculas al azar.

Además, toda lista se leerá con una métrica que no dependa del tamaño: eficiencia de ligando (score / átomos pesados) o el residuo del ajuste por tamaño descrito arriba. En este proyecto la puntuación de Vina se usa como FILTRO de triaje, no como clasificador.

En todos los casos, el ranking final de candidatos se complementa con un re-análisis físico (MM-GBSA) y filtros de fármaco-likeness, como se describe en el documento de metodología.

El análisis completo está en:

```
analysis/INFORME_VALIDACION_SOD1_2026-09-20.md
analysis/validar_sod1_v3.py
analysis/validacion_SOD1_v3/analisis_sod1_v3.csv
analysis/AUDITORIA_POSITIVOS_2026-09-20.md
```

analysis/auditar_positivos_sod1.py

analysis/auditar_similitud_tdp43.py

analysis/redocking_trp32/INFORME_CONTROLES_CORREGIDOS_2026-09-20.md